FICHE DE DÉCLARATION D'USAGE DE L'IA GÉNÉRATIVE
École Nationale des Sciences de l'Informatique

I. IDENTIFICATION DU TRAVAIL

Module : **Big Data (II3)**

Titre du Projet / Devoir/Activité : **FlowGuard : détection en temps réel d'intrusions réseau et d'anomalies zero-day (Kafka, Spark Structured Streaming, autoencodeur ONNX)**

Étudiant(e) : **Mohammed Amine Chaieb** Date : **10 / 11 / 2026**

Zone d'usage autorisée par l'enseignant : [ ] Zone 1 [ ] Zone 2 **[X] Zone 3** [ ] Zone 4

II. DESCRIPTION DE L'ASSISTANCE

Outil(s) utilisé(s) : **Claude (Anthropic), utilisé via Claude Code (session cloud)**

Version utilisée : **Claude Opus 5.5 (claude-opus-5-5)**

Nature précise de l'aide apportée :

[X] Idéation/Brainstorming : Structuration du problème, recherche d'approches algorithmiques.

[X] Génération de code : Création de squelettes, de fonctions isolées ou de tests unitaires.

[X] Débogage/Optimisation : Analyse d'erreurs, refactorisation pour gain de complexité.

[X] Rédaction/Documentation : Aide à la structuration du rapport ou des commentaires.

III. JOURNAL ANALYTIQUE DES PROMPTS (Obligatoire pour Zones 3 & 4)

Ce tableau doit démontrer votre rôle de "pilote".

Étape / Module	Intention du Prompt (Pourquoi ?)	Réponse de l'IA	Votre Validation / Critique / Correction
Git / fusion (PR #3)	Comprendre les conflits de fusion avec main sans perdre le travail des coéquipiers.	Analyse des conflits (docker-compose, producer, requirements) et commandes git pas à pas.	Commandes exécutées par moi ; vérification que les deux branches sont intactes avant la fusion.
Docker / Spark	Corriger les erreurs d'incompatibilité de versions lors de l'inférence dans Spark.	Diagnostic (scikit-learn 1.7.2 vs 1.9.1, Java 21, chemin spark-submit) ; Dockerfile et compose corrigés.	Image reconstruite et testée : 200 événements Kafka scorés par le modèle dans Spark.
Cassandra / Spark (latence)	Mesurer la latence de bout en bout et le débit du pipeline.	send_ts dans le producteur, latency_ms et scored_at, table batch_metrics, latency_report.py.	Testé sur des rejeus réels ; erreur de schéma (latency_ms absent de alerts) détectée et corrigée.
Automatisation / HDFS / démo	Lancer tout le pipeline en une commande et archiver le flux brut dans HDFS.	Service cassandra-init, provisioning Grafana, job d'archive HDFS, run_demo.ps1, jeu de démo mixte.	Exécuté de bout en bout sur ma machine ; bugs détectés et corrigés (voir partie IV).
Tableau de bord Grafana	Requêtes CQL et panneaux lisibles (anomalies par label réel, tri, limites).	JSON du dashboard, requêtes CQL, transformations Grafana.	Chaque panneau vérifié dans Grafana ; requêtes invalides corrigées après test.
Baselines / évaluation	Comparer l'autoencodeur à Isolation Forest, One-Class SVM et Random Forest.	train_baselines.py et comparaison dans evaluate.py (tableaux, courbes ROC/PR).	Version approchée du One-Class SVM rejetée (rappel 0 %) ; résultats vérifiés dans results/.
Documentation / soutenance	Documentation cohérente avec le code et support de présentation.	README, répartition du travail, diapositives.	Relecture complète ; chiffres vérifiés contre results/ ; corrections demandées (latence, mise en page).

IV. AUTO-ÉVALUATION & VALIDATION

Analyse de fiabilité : Quelles erreurs ou imprécisions (hallucinations) avez-vous détectées dans les propositions de l'IA ?

– Requête CQL invalide pour Grafana (LIMIT placé après ALLOW FILTERING) : erreur affichée, corrigée.

– Script de démo : le lien Grafana utilisait « d » au lieu de « demo » (liste PowerShell à un élément).

– make_demo_dataset.py : les étiquettes d'attaque étaient perdues avec pandas 3 (groupby.apply), détecté en vérifiant le nombre de flux par classe.

– Première version du One-Class SVM (approximation Nystroem) : rappel de 0 % sur les données de test, remplacée.

– Panneau « anomalies par label » n'affichant qu'une seule catégorie (séries non fusionnées), corrigé.

– Chiffres de latence de la présentation différents du rapport commité, remplacés par results/latency_report.csv.

Test & Exécution : Confirmez-vous avoir testé l'intégralité du code généré dans votre environnement de développement ? **[X] Oui [ ] Non**

Explicabilité : Êtes-vous en mesure d'expliquer la logique de chaque ligne soumise lors d'un entretien oral ? **[X] Oui [ ] Non**

V. ENGAGEMENT DE L'ÉTUDIANT

"Je certifie que ce travail a été réalisé conformément aux règles de la zone d'usage définie par l'enseignant. J'atteste avoir validé personnellement l'exactitude des informations, la sécurité du code et la conformité aux exigences du cours. Je comprends que toute dissimulation d'usage ou toute soumission de code dont je ne peux expliquer le fonctionnement constitue une violation de l'intégrité académique."

Signature : _____